

KREDİ KARTI DOLANDIRICILIK TESPİTİ (FRAUD DETECTION): XGBOOST VE MAKİNE ÖĞRENİMİ TABANLI UÇTAN UCA WEB UYGULAMASI PROJE RAPORU

1. Özet (Abstract)

Bu proje kapsamında, finansal veri setleri üzerinde makine öğrenimi teknikleri kullanılarak kredi kartı işlemlerinin yasal (normal) veya dolandırıcılık (fraud) olarak sınıflandırıldığı uçtan uca bir sistem geliştirilmiştir. Proje; veri ön işleme, sınıf dengesizliğinin giderilmesi, model eğitimi ve son kullanıcıya hitap eden dinamik bir web arayüzünün inşası aşamalarından oluşmaktadır. Algoritma olarak XGBoost tercih edilmiş, dengesiz veri problemi SMOTE tekniği ile çözülmüş ve sistem Nesne Yönelimli Programlama (OOP) prensiplerine sadık kalınarak tasarlanmıştır.

2. Giriş ve Problem Tanımı

Günümüzde dijital finansal işlemlerin artmasıyla birlikte kredi kartı dolandırıcılığı, bankacılık sektörü için en kritik problemlerden biri haline gelmiştir. Bu problemin veri bilimi tarafındaki en büyük zorluğu "dengesiz veri (imbalanced data)" yapısıdır. Milyonlarca yasal işlemin arasında sahte işlemlerin oranı genellikle %1'den bile azdır. Bu durum, standart makine öğrenimi modellerinin sahte işlemleri gözden kaçırarak çoğunluk sınıfını ezberlemesine yol açmaktadır. Bu projenin amacı, azınlık sınıfını (dolandırıcıları) yüksek doğrulukla yakalayabilen (yüksek Recall) ve aynı zamanda modern bir web arayüzü ile kullanılabilen bir ikili sınıflandırma (binary classification) mimarisi kurmaktır.

3. Veri Seti ve Ön İşleme (Preprocessing)

Projede kullanılan Kaggle Credit Card Fraud Detection veri seti, kişisel verilerin korunması amacıyla V1'den V28'e kadar PCA (Temel Bileşenler Analizi) işleminden geçmiş gizli sayısal değişkenler ile işlem tutarı (Amount) ve zaman (Time) değişkenlerini içermektedir. Ön işleme aşamasında şu adımlar uygulanmıştır:

- **Ölçeklendirme (Scaling):** PCA işlemine girmemiş olan 'Time' ve 'Amount' değişkenleri, modelin matematiksel hesaplamalarında ağırlık dengesizliği yaratmaması için StandardScaler kullanılarak standartlaştırılmıştır.
- **Veri Dengeleme (SMOTE):** Eğitim veri setindeki sahte işlemlerin azlığı sorununu çözmek için Imbalanced-Learn kütüphanesinin SMOTE (Synthetic Minority Over-sampling Technique) algoritması kullanılmıştır. Sentetik veri üretimi sadece eğitim (%80) setine uygulanmış, modelin gerçek dünya performansını ölçmek için test setine (%20) dokunulmamıştır.

4. Kod Mimarisi ve Model Eğitimi

Projenin yazılım mimarisi, "Clean Code" ve "Single Responsibility Principle (Tek Sorumluluk Prensipleri)" gözetilerek Nesne Yönelimli Programlama (OOP) formatında inşa edilmiştir.

- **Modüler Sınıf Yapısı:** Eğitim süreci FraudDetectionTrainer, arayüz süreci ise FraudDetectionApp adlı sınıflar altında toplanmıştır.
- **Kod Kalitesi ve Dokümantasyon:** Tüm fonksiyonlar ve sınıflar için Google formatında standart "Docstring" açıklamaları eklenmiş ve Python "Type Hint" (tip belirteçleri) kullanılarak kodun okunabilirliği ve bakımı profesyonel standartlara çekilmiştir.
- **Algoritma:** Yüksek işlem hacmi ve ağaç tabanlı yapısı sayesinde karmaşık verilerdeki örüntüleri iyi yakalayan XGBClassifier modeli eğitilmiş ve sistemin motoru olarak kaydedilmiştir.

5. Web Arayüzü ve Kullanıcı Deneyimi (UI/UX)

Makine öğrenimi modelinin son kullanıcı tarafından test edilebilmesi için Python tabanlı Streamlit kütüphanesi kullanılarak bir web dashboard (gösterge paneli) geliştirilmiştir.

- **Sekmeli Yapı:** Sistem; "Anlık Analiz Paneli", "İşlem Geçmişi" ve "Model Açıklanabilirliği (XAI)" olmak üzere üç ana sekmeye ayrılarak sade ve ferah bir UX

(Kullanıcı Deneyimi) sunmaktadır.

Kredi Kartı Dolandırıcılık Tespit Sistemi

Bu sistem, finansal işlem verilerini analiz ederek makine öğrenimi algoritmalarıyla anormallik tespiti yapmaktadır.

Sistem Özeti

Toplam Sorgu

1

Sahte

1

Onaylanan Normal İşlem

0

Kredi Kartı Dolandırıcılık Tespit Merkezi

Anlık Analiz Paneli

İşlem Geçmiş

Model Açıklanabilirliği (XAI)

Bir İşlem Seçin

Güvenli İşlem Simüle Et

Şüpheli İşlem Simüle Et

İşlem Detayları

İşlem Tutarı (Amount)

\$3.90

İşlem Zamanı (Time)

155535

Makine Öğrenimi Arka Plan Verilerini Göster (V1-V28)

Model Tahmini

DİKKAT: DOLANDIRICILIK ŞÜPHESİ! (Modelin Eminlik Oranı %100)

- Session State:** Oturum hafızası kullanılarak, kullanıcının o anki oturumda gerçekleştirdiği simülasyonlar kaydedilmekte ve dinamik sayaçlar ile ekranda anlık olarak gösterilmektedir.

Kredi Kartı Dolandırıcılık Tespit Sistemi

Bu sistem, finansal işlem verilerini analiz ederek makine öğrenimi algoritmalarıyla anormallik tespiti yapmaktadır.

Sistem Özeti

Toplam Sorgu

13

Sahte

7

Onaylanan Normal İşlem

6

Kredi Kartı Dolandırıcılık Tespit Merkezi

Anlık Analiz Paneli

İşlem Geçmiş


Model Açıklanabilirliği (XAI)

Geçmiş Sorgulamalar

İşlem Tutarı	Zaman	Gerçek Sınıf	Model Tahmini	Güven Skoru
0 \$3.90	155535	Dolandırıcı (1)	Dolandırıcı (1)	%100
1 \$105.86	141262	Normal (0)	Normal (0)	%100
2 \$59.85	83197	Normal (0)	Normal (0)	%100
3 \$119.74	102676	Dolandırıcı (1)	Dolandırıcı (1)	%100
4 \$12.89	145913	Normal (0)	Normal (0)	%100
5 \$99.99	28755	Dolandırıcı (1)	Dolandırıcı (1)	%100
6 \$25.00	130610	Normal (0)	Normal (0)	%100
7 \$1.00	8415	Dolandırıcı (1)	Dolandırıcı (1)	%100
8 \$3.75	169092	Normal (0)	Normal (0)	%100
9 \$824.83	70536	Dolandırıcı (1)	Dolandırıcı (1)	%100

6. Açıklanabilir Yapay Zeka (Explainable AI - XAI)

Makine öğrenimi modellerinin genellikle "siyah kutu" (black box) olarak görülmesi sorununu aşmak için projeye XAI entegrasyonu yapılmıştır. Arayüzdeki üçüncü sekmede, XGBoost modelinin .feature_importances_ özelliği kullanılarak tahmin esnasında modelin en çok hangi değişkenlere (Örn: V14, V4, Amount vb.) dikkat ettiği, Altair kütüphanesi ile çizilen dinamik yatay çubuk grafiklerle kullanıcıya şeffaf bir şekilde sunulmaktadır.



7. Performans Metrikleri ve Değerlendirme

Eğitilen XGBoost modelinin test seti üzerindeki performansı incelendiğinde; "Recall" (Duyarlılık/Gerçek sahteleri yakalama oranı) değerinin yaklaşık %88 - %89 seviyelerine ulaştığı görülmüştür. Bankacılık sektöründe gerçek bir dolandırıcının işlemini onaylamak, masum bir müşteriye yanlış alarm (düşük Precision) vermekten çok daha maliyetlidir. Bu nedenle projedeki model, gerçek dünya finansal senaryolarına uygun olarak Precision-Recall Trade-off (ödünleşim) dengesinde, Recall'u maksimize edecek şekilde başarıyla kurgulanmış ve test edilmiştir.

8. Sonuç

Geliştirilen bu proje; arka planda istatistiksel veri işleme yeteneklerini, algoritmik modelleme becerilerini ve kod kalitesi standartlarını (OOP, Clean Code) barındırırken; ön yüzde modern ve anlaşılır bir kullanıcı arayüzü sunmayı başarmıştır. Modelin anormallikleri tespit etmedeki yüksek başarısı ve şeffaf karar mekanizması, uygulamanın amacına tam olarak hizmet ettiğini kanıtlamaktadır.